Forecasting Prevalensi Diabetes di Indonesia dengan ARIMA
Projek Sains Data - RA

Irhamna Mahdi - 122450049
Alvia Asrinda Br.Ginting - 122450077
Rendra Eka Prayoga - 122450112

A. Deskripsi

Penelitian ini berfokus pada upaya memprediksi tren prevalensi diabetes di Indonesia menggunakan pendekatan deret waktu berbasis model Autoregressive Integrated Moving Average (ARIMA). Data yang digunakan merupakan data resmi dari World Health Organization (WHO) yang telah difilter khusus untuk wilayah Indonesia. Dataset tersebut menyediakan dua kategori utama, yaitu age-standardized prevalence dan crude prevalence, yang masing-masing merepresentasikan prevalensi diabetes dengan penyesuaian umur serta prevalensi kasar pada populasi secara umum. Kedua kelompok data ini dianalisis untuk memahami dinamika temporal prevalensi diabetes serta mengevaluasi perbedaan pola yang mungkin muncul akibat perbedaan metode pengukuran epidemiologis.

Proses analisis dimulai dengan eksplorasi deret waktu untuk mengidentifikasi pola tren, stasioneritas, dan potensi autokorelasi. Model ARIMA kemudian dibangun melalui tahapan differencing, pemilihan orde (p, d, q), serta evaluasi diagnostik residual guna memastikan model memenuhi asumsi statistik yang diperlukan. Dengan menggunakan model terbaik yang diperoleh, penelitian ini menghasilkan proyeksi prevalensi diabetes Indonesia pada periode mendatang. Hasil forecasting diharapkan dapat memberikan gambaran awal bagi pemangku kebijakan dalam merumuskan strategi pencegahan dan pengendalian diabetes, mengingat meningkatnya prevalensi penyakit ini memiliki implikasi signifikan terhadap beban kesehatan nasional. Penelitian ini secara keseluruhan berkontribusi dalam menyediakan dasar ilmiah berbasis data untuk mendukung perencanaan kesehatan publik di Indonesia.

B. Hipotesis Awal

1. H1: Terdapat pola tren yang signifikan pada data prevalensi diabetes di Indonesia sehingga model ARIMA dapat memodelkan dan memprediksi perubahan prevalensi di masa mendatang secara akurat. Hipotesis ini didasarkan pada asumsi bahwa prevalensi diabetes, baik dalam kategori age-standardized maupun crude, menunjukkan karakteristik deret waktu yang dapat diidentifikasi melalui komponen tren, autokorelasi, atau pola sistematis lainnya. Dengan demikian, pendekatan ARIMA diperkirakan mampu menangkap dinamika temporal tersebut secara efektif setelah proses transformasi serta differencing dilakukan untuk mencapai stasioneritas.

2. H2: Terdapat perbedaan dinamika deret waktu antara prevalensi age-standardized dan crude yang dapat menghasilkan parameter ARIMA berbeda untuk masing-masing kelompok data. Hipotesis ini mencerminkan dugaan bahwa penyesuaian umur (age-standardization) mengubah struktur variabilitas dan autokorelasi pada data sehingga mempengaruhi pemilihan orde optimal ARIMA. Dengan demikian, masing-masing kategori diprediksi memerlukan konfigurasi parameter model yang berbeda dalam proses pemodelan.

3. H0 (Hipotesis Nol): Tidak terdapat pola signifikan dalam data prevalensi diabetes di Indonesia, sehingga model ARIMA tidak memberikan performa prediksi yang lebih baik dibandingkan model acak (naïve). Hipotesis nol ini digunakan sebagai pembanding untuk menguji apakah model ARIMA benar-benar mampu menangkap struktur deret waktu atau apakah data bersifat acak dan tidak dapat dimodelkan secara memadai.

C. Sumber data
Sumber:
https://www.who.int/data/gho/data/indicators/indicator-details/GHO/prevalence-of-diabetes-age-standardized

Data yang digunakan dalam penelitian ini bersumber dari World Health Organization (WHO) melalui platform Global Health Observatory (GHO), khususnya pada indikator Prevalence of Diabetes (Age-Standardized). Indikator ini menggambarkan persentase penduduk usia 18 tahun ke atas yang memenuhi kriteria klinis diabetes berdasarkan kadar glukosa plasma puasa ≥ 7 mmol/L, nilai HbA1c ≥ 6,5%, atau penggunaan obat penurun glukosa. WHO menyediakan dua kelompok data utama, yaitu age-standardized prevalence, yang telah disesuaikan dengan standar umur WHO untuk memungkinkan perbandingan lintas waktu maupun lintas populasi, serta crude prevalence, yang merepresentasikan prevalensi kasar tanpa penyesuaian struktur umur. Estimasi prevalensi yang dipublikasikan oleh WHO berasal dari survei kesehatan representatif nasional maupun sub-nasional yang mengukur biomarker klinis terkait diabetes, serta dilengkapi dengan pemodelan meta-regresi hirarki Bayesian untuk mengatasi keterbatasan data yang tidak lengkap pada setiap negara dan setiap tahun. Dengan metodologi yang ketat dan transparan, data WHO GHO memberikan landasan empiris yang kuat untuk analisis deret waktu, sehingga layak digunakan sebagai dasar dalam peramalan prevalensi diabetes di Indonesia menggunakan model ARIMA.

D. Pre-processing Data
Tahap preprocessing pada penelitian ini dimulai dengan pemuatan data mentah dari file data_psd.csv yang berisi berbagai indikator kesehatan dari WHO, termasuk prevalensi diabetes. Pada tahap awal ini, seluruh atribut seperti jenis indikator, jenis

kelamin, kelompok umur, dan nilai numerik prevalensi masih tercakup secara keseluruhan. Oleh karena itu, langkah seleksi data menjadi esensial untuk memastikan bahwa hanya informasi yang relevan dengan tujuan penelitian yang diproses lebih lanjut. Pendekatan ini memastikan bahwa analisis dilakukan pada data yang bersih, konsisten, dan sesuai konteks epidemiologis yang ingin dikaji.

Langkah berikutnya adalah melakukan penyaringan data berdasarkan indikator yang sesuai dengan fokus penelitian. Seleksi berbasis atribut ini merupakan bagian penting dalam preprocessing, karena ARIMA membutuhkan deret waktu yang homogen dan merepresentasikan fenomena yang sama sepanjang periode observasi.

Setelah proses penyaringan, data diurutkan berdasarkan variabel Period untuk membentuk struktur kronologis yang benar. Pengurutan ini bersifat fundamental dalam analisis deret waktu karena ARIMA bekerja dengan asumsi bahwa observasi tersusun dalam urutan temporal yang konsisten. Data kemudian ditata ulang dengan memilih dua kolom penting, yaitu Period sebagai variabel waktu dan FactValueNumeric sebagai nilai prevalensi. Kedua kolom ini kemudian dinamai ulang menjadi Year dan Prevalence, lalu Year dijadikan indeks deret waktu. Transformasi ini memastikan bahwa data memenuhi format yang dibutuhkan untuk analisis statistik deret waktu dan memudahkan proses interpretasi maupun visualisasi.

Tahap preprocessing ditutup dengan pemeriksaan awal terhadap struktur dan karakteristik data, termasuk rentang tahun, jumlah observasi, serta beberapa baris pertama dan terakhir data. Langkah verifikasi ini dilakukan untuk memastikan tidak adanya nilai hilang, inkonsistensi, atau kesalahan struktural sebelum data digunakan dalam pengujian stasioneritas dan pemodelan ARIMA. Secara keseluruhan, preprocessing yang dilakukan telah membangun fondasi yang kuat bagi analisis berikutnya, memastikan bahwa model ARIMA yang digunakan beroperasi pada data yang bersih, terstruktur, dan representatif sesuai konteks prevalensi diabetes di Indonesia.

E. Pembagian Tugas
    1. Irhamna Mahdi
       Tugas: Merancang code
    2. Alvia Asrinda Br.Ginting
       Tugas: Penulisan laporan
    3. Rendra Eka Prayoga
       Tugas: Pembuatan bahan presentasi